

Metody Probabilistyczne i Statystyka – zadanie domowe nr 2

Szymon Hładyszewski

Kody źródłowe zostały napisane w języku Java w oparciu o Maven, aby można było zastosować generator Mersenne Twister. Wszelkie otrzymane wyniki są zapisywane w pliku .csv, a wykresy zostały wygenerowane w Excelu.

Opis i rezultaty poszczególnych wykresów, koncentracja uzyskanych wyników i wnioski:

Na pierwszych pięciu poniżej przedstawionych wykresach małe niebieskie kropki oznaczają pojedyncze wyniki dla danej ilości urn. Większe czerwone kropki symbolizują średni wynik z pięćdziesięciu powtórzeń eksperymentu dla każdej poszczególnej ilości koszyków. Na pozostałych wykresach kropki dotyczą jedynie średnich wartości dla każdej iteracji ilości tychże urn.

1. B_n – na wykresie można dostrzec, że wraz ze wzrostem liczby koszyków – n , liczba rzutów kul do momentu uzyskania kolizji również rośnie. Jednakże wzrost ten jest zadziwiająco coraz mniejszy. Oprócz tego widoczny jest niemały rozrzut, zwłaszcza dla dużych n .
2. U_n – wykres ten rośnie wręcz liniowo, a pojedyncze próby są do siebie bardzo podobne, przez co każda z nich jest bardzo zbliżona do wartości średniej dla każdego n .
3. C_n oraz D_n – wykresy zgodne z przewidywaniami, widoczne dla obu z nich rezultaty wskazują, że rozrzut dla poszczególnych eksperymentów jest stosunkowo niewielki.
4. $D_n - C_n$ – podobnie jak przy B_n , widać tutaj duży rozrzut, zwłaszcza przy wynikach dla dużej ilości urn.

Asymptotyka:

1. $b(n)$ – rośnie w tempie \sqrt{n} , co wynika z wykresu $b(n)/\sqrt{n}$, gdzie wartości średnie można przybliżyć do stałej różnej od zera oraz klasycznego rozwiązania problemu paradoksu urodzinowego.
2. $u(n)$ – wzrost wynosi n , co również wynika z wykresu funkcji $u(n)/n$ (wyniki można aproksymować do stałej różnej od zera).
3. $c(n)$ – aproksymacja wykresu $c(n)/(n \cdot \ln(n))$ posiada wartości stałe i różne od zera, zatem $c(n)$ rośnie w tempie $n \cdot \ln(n)$, co jest zgodne z rozwiązaniem problemu kolekcjonera kuponów.
4. $d(n)$ – identyczna sytuacja jak w przypadku $c(n)$.
5. $d(n) - c(n)$ – rośnie w tempie $n \cdot \ln(\ln(n))$ na podstawie wykresu $(d(n) - c(n))/(n \cdot \ln(\ln(n)))$.

Birthday paradox – nazwa odnosi się do paradoksu, w którym szacujemy, ile potrzeba osób w grupie, aby była spora szansa na to, że znajdują się w niej dwie osoby o takiej samej dacie urodzin. Okazuje się, że liczba ta jest znacznie mniejsza niż się to wydaje. Analogicznie jest z wystąpieniem kolizji podczas wrzucania kul do urn – z każdym kolejnym powiększaniem ilości koszyków o tysiąc, moment uzyskania jej opóźnia się dosłownie o kilka rzutów.

Coupon collector's problem – użycie tej nazwy wynika z problemu jak długo kolekcjoner musi zbierać kupony, aby uzyskać je wszystkie, gdzie każdy z nich jest wydawany losowo. Analogiczna sytuacja ma miejsce przy szacowaniu ilości rzutów potrzebnej do zapełnienia każdej urny przynajmniej jedną kulą.

Znaczenie birthday paradox przy funkcjach hashujących i kryptograficznych funkcjach hashujących:

Paradoks ten jest tutaj dosyć istotny, ponieważ występuje tutaj analogia pomiędzy znalezieniem drugiej osoby z tą samą datą urodzin (birthday paradox) oraz znalezieniem danych generujących identyczny hash, który chcemy wydobyć (funkcja hashująca).













